



Московский государственный университет имени М.В. Ломоносова
Факультет вычислительной математики и кибернетики
Кафедра математической статистики

Педашенко Владислав Евгеньевич

Спектральное вейвлет преобразование для задачи непараметрической регрессии

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Научный руководитель:

д.ф.-м.н., профессор

Шестаков Олег Владимирович

Москва, 2022

Оглавление

1	Введение	3
2	Обработка графовых сигналов и вейвлеты	5
2.1	Иллюстративный пример нерегулярного сигнала	5
2.2	Графовое преобразование Фурье	6
2.3	Недостаток преобразования Фурье	8
2.4	Спектральное графовое вейвлет преобразование	8
2.5	Каркасы	9
3	Методы удаления шума	11
3.1	Универсальный порог	11
3.2	SURE порог	12
3.3	Применение к временным рядам	12
4	Численные результаты	14
4.1	Применение СГВП к временным рядам	14
4.1.1	Данные	14
4.1.2	Результаты экспериментов	16
4.1.3	Интерпретация полученных результатов	19
4.2	Применение SURE порога	20
4.2.1	Генерация сигнала	20
4.2.2	Результаты экспериментов	21
4.2.3	Интерпретация полученных результатов	22
5	Заключение	24

1 Введение

Графовая обработка сигналов ¹ [9] - это область, главная цель которой это разработка методов для обработки данных определенных на нерегулярных графах. Одной из ключевых направлений в данной области - это обобщение методов классической обработки сигналов на нерегулярную графовую область, в частности вейвлетов. Одни из классических приложений графовой обработки сигналов являются сжатие, удаление шума, восстановление данных с сети сенсоров, анализ биологических сетей.

В 2011 году Hammond [1] предложил общую конструкцию каркаса ², которая наследует обычные свойства вейвлетов: каждый вектор в каркасе локализован в графовой и спектральной области. Преобразование, соответствующее этому каркасу было названо Спектральным Графовым Вейвлет Преобразованием(СГВП) ³. СГВП часто используется для обработки сложно структурированных данных таких как, например сети [12], [1]. Аналогично Дискретному Вейвлет Преобразованию(ДВП) СГВП определяется спектральным графовым вейвлет ядром ⁴ и ядром масштабирующей функции ⁵, которые имеют характеристики низкочастотного фильтра и полосового фильтра. Т.к. полосовой фильтр плохо улавливает низкие частоты, то ядро масштабирующей функции используется для описания низкочастотной информации сигнала. С помощью СГВП, графовый сигнал может быть представлен в виде суммы сигналов с различным частотным носителем в спектральной графовом домене, что также аналогично ДВП.

Была сделана попытка обобщить классические методы удаления шума с помощью вейвлетов на нерегулярную графовую область с помощью СГВП. В частности, в [2] было показано, что оценка, полученная с помощью использования универсального порога и мягкой пороговой обработки, удовлетворяет очень похожей нижней оценке, что и в классическом случае. Также на нерегулярный случай был обобщен и SURE порог [8]. Также, придуман метод удаления шума с помощью СГВП для временных рядов [13].

В данной работе был проведен экспериментальный анализ обобщения метода SURE на графовую область, дополняющий анализ [8]. В частности, менялся уровень разложения СГВП каркаса и различные фильтры банков. Также мы провели экспериментальный анализ качества удаления шума от выбора весовой функции в методе, описанном в статье [13]. Эта работа организована следующим образом. В части II приведены определения и результаты, которые относятся к спектральной теории графов, жестким

¹(англ.)Graph signal processing

²(англ.) frame

³(англ.) Spectral Graph Wavelet Transform(SGWT)

⁴(англ.) spectral graph wavelet kernel

⁵(англ.) scaling function kernel

каркасам и СГВП. Данные определения и результаты нужны для определения методов удаления шума, основанных на СГВП, которые представлены в части III. В части IV проведён экспериментальный анализ вышеупомянутых методов. В пятой части подведены итоги работы.

2 Обработка графовых сигналов и вейвлеты

2.1 Иллюстративный пример нерегулярного сигнала

Классические методы обработки сигналов придуманы для сигналов, которые упорядочены во времени и их можно представить в виде регулярной решетки. Однако, в последнее время с развитием социальных сетей, компьютерных сетей и нейронауки все чаще требуется обрабатывать сигналы, которые имеют нерегулярную структуру. Давайте рассмотрим пример такого нерегулярного сигнала подробнее. Пусть есть данные с сети метеостанций y_n , которая измеряет температуру см. рис. 2.1 [14] и известно, что данные являются зашумленными, как и многие физические данные, например, из-за неблагоприятных воздействий местной среды на показания датчика или его неисправную работу. Для простоты будем считать, что шум является аддитивным белым гауссовским.




Рис. 2.1: Сеть метеостанций

Замечание. В данном случае, затруднительно применить классические методы обработки сигналов, которые требуют упорядочивание исходного сигнала, однако упорядочить данный сигнал на графе сложно, т.к. сигнал определен на нерегулярном графе, и ввести какое-то разумное упорядочивание вершин графа без потери информации неочевидно.

Исходя из физических соображений, разумно предположить, что температура у датчиков, которые находятся близко друг от друга и расположены примерно на одинаковой высоте будет довольно близка. Этот факт можно формализовать с помощью взвешенных ребер. Веса будут иметь следующий смысл: чем больше вес, тем, скорее всего, меньше разность температур между этими двумя вершинами. Существует следующий популярный способ задания весов для графа [14]: вес между вершинами i и j будет

задаваться следующей формулой:

$$\omega_{ij} = \begin{cases} \exp\left(\frac{\|v_i - v_j\|_2^2}{2\sigma^2}\right), & \|v_i - v_j\|_2 > t \\ 0, & \text{иначе,} \end{cases} \quad (2.1)$$

где t, σ некоторые положительные величины, а v_i и v_j это сигнал, который ассоциирован с i -ой и j -ой вершиной соответственно.

Для обработки подобных сигналов был разработан аппарат графовой обработки сигналов (ГОС) [9]. В частности, ГОС обобщает некоторые методы классической обработки сигналов с помощью введения графового преобразования Фурье, о котором пойдет речь ниже.

2.2 Графовое преобразование Фурье

Пусть $G = \{E, V, \omega\}$ - взвешенный граф, где V - множество вершин, E - множество ребер и $\omega : E \rightarrow \mathbb{R}^+$, весовая функция, которая ставит в соответствие каждому ребру неотрицательный вес. Пусть $|V| = N < +\infty$. Рассмотрим матрицу весов $W = (w_{ij})_{i,j=1}^N$ и

$$w_{m,n} = \begin{cases} \omega(e), & \text{если } e \in E \text{ и соединяет вершины } m \text{ и } n \\ 0, & \text{иначе} \end{cases} \quad (2.2)$$

Здесь и далее будем рассматривать графы неориентированные, без петель и кратных ребер с неотрицательными весами.

Определение: Комбинаторным Лапласианом графа G назовем матрицу $\mathcal{L} = \mathbb{L} = D - W$, где $D = \text{diag}(\sum_{n=1}^N w_{m,n}, 1 \leq m \leq n)$. Также матрицу $\mathcal{L}$ называют матрицей Лапласа графа G .

Свойства Лапласиана [9]:

- Лапласиан является неотрицательно определенной симметричной матрицей, следовательно, существует ортонормированный базис из собственных векторов Лапласиана и все его собственные значения неотрицательны.
- Лапласиан является графовым аналогом одномерного оператора Лапласа на прямой.
- Для произвольного сигнала $f \in \mathbb{R}^N$ справедливо [9]:

$$S(f) = f^T L f(i) = \sum_{j \in \mathcal{N}_i} \omega_{i,j} [f(i) - f(j)]^2, \quad (2.3)$$

где $\mathcal{N}_i$ - множество вершин смежных с вершиной i . Причем, чем больше значение $S(f)$, тем более высокочастотным будет спектр сигнала f и наоборот.

- Чем больше собственное значение, которое соответствует собственному вектору матрицы Лапласа, тем менее гладким будет соответствующий собственный вектор. Это легко проверяется с помощью предыдущего пункта. Это свойство наталкивает нас на мысль, об аналогии между частотами и собственными значениями матрицы Лапласа. Эта аналогия продолжит свое развитие ниже.
- Геометрическая кратность нулевого собственного значения матрицы Лапласа совпадает с количеством компонент связности графа G .

В данной работе везде использовался только комбинаторный Лапласиан. Теперь перейдем непосредственно к определению графового преобразования Фурье. На действительной прямой комплексные экспоненты $e^{i\omega x}$, которые определяют преобразование Фурье, являются собственными функциями одномерного оператора Лапласа $\frac{d^2}{dx^2}$. Обратное преобразование Фурье

$$f(x) = \frac{1}{2\pi} \int \hat{f}(\omega) e^{i\omega x} d\omega.$$

может быть представлено как разложение f по собственным функциям оператора Лапласа.

Графовое преобразование Фурье определяется аналогично рассуждению выше. Пусть χ_l , $l = 0, \dots, N-1$ - собственный вектор матрицы Лапласа, отвечающий собственному значению λ_l

$$\mathbb{L}\chi_l = \lambda_l \chi_l \quad (2.4)$$

Далее будем предполагать, что граф G является связным и отсортируем собственные значения в порядке возрастания:

$$0 = \lambda_0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_{N-1} = \lambda_{max}.$$

Определение. Преобразованием Фурье графового сигнала $f \in \mathbb{R}^N$ определенного на вершинах графа G будем называть вектор $\hat{f} \in \mathbb{R}^N$, компоненты которого определяются следующим равенством:

$$\hat{f}(l) = \langle \chi_l, f \rangle = \sum_{n=1}^N \chi_l^* f(n), \quad 1 \leq l \leq N \quad (2.5)$$

Обратное графовое преобразование Фурье задается следующей формулой:

$$f(n) = \sum_{l=0}^{N-1} \hat{f}(l) \chi_l(n) \quad (2.6)$$

Пусть $f, h \in \mathbb{R}^N$ - графовые сигналы, а $\hat{f}, \hat{g} \in \mathbb{R}^N$ их графовые преобразования Фурье. Тогда справедливо равенство Парсеваля:

$$\forall f, g \in \mathbb{R}^N \quad \langle f, g \rangle = \langle \hat{f}, \hat{g} \rangle \quad (2.7)$$

В данном варианте построения графового преобразования Фурье, аналогами частот являются собственные значения графа Лапласиана, собственными функциями, по которым происходит разложение, являются собственные векторы матрицы Лапласа. В частности поэтому, построив графовое преобразование Фурье мы можем применить следующий стандартный прием для удаления шума, который состоит из следующих шагов: применить графовое преобразование Фурье, убрать высокие частоты и применить обратное графовое преобразование Фурье.

2.3 Недостаток преобразования Фурье

Прежде чем пойти дальше, хотелось обсудить одно преимущество, которым обладает классическое вейвлет преобразование по сравнению с преобразованием Фурье.

Преобразование Фурье дает информацию только о частотной характеристике сигнала, но не дает локализации по времени, что является существенным ограничением при применении его к нестационарным сигналам. Однако, можно построить оконное преобразование Фурье, которое уже имеет локализацию в частотно-временной области, однако все же есть проблемы с детектированием сигналов, у которых высокая частота и при этом малая временная продолжительность, а также с сигналами, которые имеют низкую частоту и большую временную продолжительность, см. [3]. Этого недостатка лишены вейвлеты.

Ниже будет описано обобщение вейвлетов на нерегулярную графовую область [1].

2.4 Спектральное графовое вейвлет преобразование

Спектральное графовое вейвлет преобразование было определено в [1], ниже мы кратко приведем схему его построения. Спектральное графовое вейвлет преобразование (СГВП) является аналогом классического вейвлет преобразования и определяется в спектральной области, а потом с помощью обратного графового преобразования Фурье переносится во временную(вершинную) область. Для определения СГВП нужно задать две функции $g(x) : \mathbb{R} \rightarrow \mathbb{R}$ и $h(x) : \mathbb{R} \rightarrow \mathbb{R}$, которые обладают следующими свойствами: $g(x) \geq 0, \forall x \in \mathbb{R}, g(0) = 0, \lim_{x \rightarrow +\infty} g(x) = 0, h(0) > 0, h(x) \geq 0, \forall x \in \mathbb{R}, \lim_{x \rightarrow +\infty} h(x) = 0$. Функции $g(x)$ и $h(x)$ задают графовые преобразования Фурье вейвлета и масштабирующей функции. Далее, с помощью обратного графового преобразования Фурье, определяются вейвлет $\psi_{t,n}(x)$ и масштабирующая функция $\phi_n(x)$ в вершинной(временной) области. По построению, параметр n отвечает за пространственную локализацию: вектор $\psi_{t,n}$ локализован вокруг вершины n , а параметр t - масштаб, отвечает за спектральную локализацию. А сами вейвлет коэффициенты определяются как: $W_f(t, n) = \langle \psi_{t,n}, f \rangle$, $S_f(n) = \langle \phi_n, f \rangle$.

СГВП каркас

Определение. Множество векторов $\{r_i\}_{i \in I} = \mathfrak{F}$, $r_i \in \mathbb{R}^{|V|}$ называется каркасом векторов, если существуют такие константы $A > 0, B > 0$, что для любого вектора $f \in \mathbb{R}^{|V|}$ справедливо равенство:

$$A\|f\|_2^2 \leq \sum_{i \in I} |\langle f, r_i \rangle|^2 \leq B\|f\|_2^2 \quad (2.8)$$

Каркас называется каркасом Парсеваля, если $A = B = 1$.

Пусть фиксировано множество масштабов $\{t_i\}_{i=1}^J$. Тогда СГВП каркас $\mathfrak{F}$ следующим образом: $\mathfrak{F} = \{\phi_n\}_{n=1}^N \cup \{\psi_{t_j, n}\}_{1 \leq j \leq J, 1 \leq n \leq N}$.

Свойства СГВП каркаса:

- Если функции $g(x)$ и $h(x)$ выбраны так, что $A = \min_{\lambda \in [0, \lambda_{max}]} G(\lambda) > 0$, где $G(\lambda) = h^2(\lambda) + \sum_j g(t_j \lambda)^2$, то СГВП обратимо.
- СГВП обеспечивают одновременную локализацию и по времени и по частоте при стремлении параметра масштаба t к нулю при определенном выборе функций g и h [1], [2].

2.5 Каркасы

Конструирование жестких каркасов

Далее будем рассматривать только каркасы Парсеваля. Ниже кратко напомним об общем способе построения таких каркасов (см. [5]).

Пусть $f \in \mathbb{R}^N$. Из свойств Лапласиана $\mathbb{L}$ следует, что справедливо следующее представление: $\mathbb{L} = \sum_{l=1}^N \lambda_l \langle \chi_l, f \rangle \chi_l$. Тогда, для произвольной функции $\rho : sp(\mathbb{L}) \rightarrow \mathbb{R}$, определенной на спектре матрицы $\mathbb{L}$, обозначим $\rho(\mathbb{L})f = \sum_l \rho(\lambda_l) \langle \chi, f \rangle \chi_l$.

Определение:[2] Конечный набор функций $\{\psi_j : \mathbb{R} \rightarrow \mathbb{R}\}_{j=0}^J$ называется разбиением единицы на отрезке $[0, \lambda_{max}]$, если $\psi_j : [0, \lambda_1] \rightarrow [0, 1]$ для всех $0 \leq j \leq J$ и $\forall \lambda \in [0, \lambda_1]$ $\sum_{j=0}^J \psi_j(\lambda) = 1$.

Разбиение единицы может быть легко получено следующим образом: пусть $\omega : \mathbb{R}^+ \rightarrow [0, 1]$ некоторая функция с носителем на отрезке $[0, 1]$, удовлетворяющая условию $\omega \equiv 1$ на $[0, b^{-1}]$, для некоторого $b > 1$. Тогда набор функций $\{\psi_j : \mathbb{R} \rightarrow \mathbb{R}\}_{j=0}^J$, определенных следующим образом:

$$\psi_0(x) = \omega(x), \quad \psi_j(x) = \omega(b^{-j}x) - \omega(b^{-j+1}x), \quad j = 1, \dots, J, \quad J = \left\lfloor \frac{\log \lambda_{max}}{\log b} \right\rfloor + 2,$$

является разбиением единицы. Например, если функция ω является кусочно-линейной, то получится следующее разбиение единицы, см. рис. 2.2.

Итак, пусть набор функций $\{\psi_j : \mathbb{R} \rightarrow \mathbb{R}\}_{j=0}^J$ является разбиением единицы, тогда следующее множество векторов $\mathfrak{F}$ является каркасом Парсеваля [8]:

$$\mathfrak{F} = \{\sqrt{\psi_j}(\mathbb{L})\delta_i, j = 0, \dots, J, i \in V\} \quad (2.9)$$

Пусть

$$\mathcal{W} = \left(\sqrt{\psi_0}(\mathbb{L})^T, \dots, \sqrt{\psi_J}(\mathbb{L})^T \right)^T \in \mathbb{R}^{n(J+1) \times n}, \quad (2.10)$$

Заметим, что для получения СГВП коэффициентов сигнала f достаточно умножить матрицу $\mathcal{W}$ на $f : \mathcal{W}f \in \mathbb{R}^{n(J+1)}$. Из-за того, что каркас является каркасом Парсеваля, следует, что сигнал $f \in \mathbb{R}^n$ может быть восстановлен по своим вейвлет коэффициентам следующим образом:

$$f = \mathcal{W}^* \mathcal{W} f, \quad (2.11)$$

т.е. $\mathcal{W}^* \mathcal{W} = I$ [1].




Рис. 2.2: Разбиение единицы компакта $[0, 15]$, $b = 2$

3 Методы удаления шума

Пусть

$$y_i = x_i + \xi_i, \quad i \in \{1, \dots, N\}, \quad (3.1)$$

где y_i - i -ая компонента наблюдаемого графового сигнала, которая соответствует i -ой вершине, $x = (x_1, \dots, x_N)$ - исходный графовый сигнал, $\xi_i \sim \mathcal{N}(0, \sigma^2)$ - независимые и одинаково распределенные случайные величины.

3.1 Универсальный порог

Пусть $\mathfrak{F} = \{\sqrt{\psi_{k,j}}\}$ каркас Парсеваля, который имеет вид 2.9. Будем оценивать коэффициенты $\langle x, \sqrt{\psi_{k,j}} \rangle$ с помощью мягкой пороговой обработки. Для этого введем функцию $S_s(z, c) = \text{sgn}(z) \max\{|z| - c, 0\}$. Тогда оценка графового сигнала x будет

$$\hat{x}_S = \sum_{k,l} S_s \left(\langle y, \sqrt{\psi_{k,l}} \rangle, t_{k,l} \right) \cdot \sqrt{\psi_{k,l}}, \quad (3.2)$$

где $c_{kl} = \sigma \|\sqrt{\psi_{k,l}}\|$.

Чтобы измерить качество оценки воспользуемся мерой риска:

$$\text{Risk}(\hat{x}, x) = \mathbb{E}_\xi (\|\hat{x} - x\|^2) \quad (3.3)$$

Для сравнения полученной оценки построим оценку оракула. Для этого определим следующую оценку:

$$\hat{x}_I = \sum_{(k,l) \in I} \langle y, \sqrt{\psi_{k,l}} \rangle \sqrt{\psi_{k,l}} \quad (3.4)$$

Тогда риск оценки оракула будет совпадать с:

$$\min_I \mathbb{E} (\|\hat{x}_I - x\|^2) = \sum_{(k,l)} \min \left(\langle x, \sqrt{\psi_{k,l}} \rangle^2, \sigma^2 \|\sqrt{\psi_{k,l}}\|^2 \right) = r_{\min}(x) \quad (3.5)$$

Теорема [2]: Пусть $\mathfrak{F} = \{\sqrt{\psi_{k,j}}\}$ - каркас Парсеваля, который имеет вид 2.9, $\hat{x}_S = \sum_{k,l} S_s(\langle y, \sqrt{\psi_{k,l}} \rangle, t_{k,l}) \cdot \sqrt{\psi_{k,l}}$ - оценка, полученная с помощью мягкой пороговой обработки. Тогда, если $t_{k,l} = \sigma \|\sqrt{\psi_{k,l}}\| \sqrt{2 \log(n)}$, то справедливо следующее неравенство:

$$\mathbb{E}(\|\hat{x}_S - x\|^2) \leq (2 \log(n) + 1)(\sigma^2 + r_{\min}) \quad (3.6)$$

3.2 SURE порог

Далее рассмотрим метод, который основан на минимизации SURE(Stein's Unbiased Risk Estimator) [8]. Для этого применим к равенству 3.1 СГВП слева и справа, что эквивалентно умножению на матрицу $\mathcal{W}$ см. равенство 2.10. Обозначим $Y = \mathcal{W}y$, $X = \mathcal{W}x$, $\mathcal{W}\xi = \Xi \sim \mathcal{N}(0, \sigma^2 \mathcal{W}\mathcal{W}^*)$. Заметим, что после умножения на матрицу $\mathcal{W}$ шум уже перестал быть независимым и стал коррелированным.

Пороговая функция $\tau(x, t)$, которая имеет смысл аналогичный пороговой функции S_s , будет иметь следующий вид: $\tau(x, t) = x \max\{1 - t^\beta |x|^{-\beta}, 0\}$, где $\beta \geq 1$, x - вейвлет коэффициент, t - порог. Заметим, что при $\beta = 1$ получается мягкая пороговая обработка, а при $\beta = +\infty$ получается жесткая пороговая обработка. Сформулируем частный случай теоремы, которая доказана в [8].

Теорема: В вышеописанных условиях SURE имеет вид:

$$SURE = -n\sigma^2 + \sum_{i=1}^{n(J+1)} Y_i^2 \left(\min \left\{ 1, \frac{t_i^\beta}{|Y_i|^\beta} \right\} \right)^2 + 2 \sum_{i=1}^n \mathbb{D}(\Xi_i) \mathbb{1}_{[t_i, +\infty)}(|Y_i|) \left[1 + \frac{(\beta - 1)t_i^\beta}{|Y_i|^\beta} \right] \quad (3.7)$$

Пороги $\{t_i\}_{i=1, \dots, n(J+1)}$ выбираются так, чтобы минимизировать SURE. Это может показаться достаточно нетривиальной задачей, однако, как показано в [8], нужные пороги могут быть найдены за $O(n(J+1)\log(n(J+1)))$.

Метод оценки дисперсии

Дисперсия шума оценивалась по следующей формуле [8]:

$$\hat{\sigma}^2 = \frac{\sum_{i,j} \omega_{i,j} |y[i] - y[j]|^2}{2Tr\mathcal{L}}. \quad (3.8)$$

Данная оценка является смещенной, но смещение очень маленькое относительно истинной величины дисперсии.

3.3 Применение к временным рядам

Этот метод удаления шума состоит из четырех частей:

- Построение графа и графового сигнала по временному ряду.
- Применение СГВП к графовому сигналу.
- Применение пороговой обработки к спектральным вейвлет коэффициентам.
- Применение обратного СГВП преобразования.

Ниже будут описаны первая и третья часть, т.к. вторая и четвертая часть уже были рассмотрены выше.

Построение сигнала на графе по временному ряду

Пусть $\{x_1, \dots, x_n\}$ - временной ряд длины n . Для задания графового сигнала необходимо задать граф. Пусть $G = \{V = \{v_1, \dots, v_n\}, E\}$ - неориентированный граф без петель и кратных ребер. Количество вершин будет совпадать с длиной временного ряда, а сам граф будет являться путем (path graph). Т.е. ребра будут только между вершинами с соседними индексами: $E = \{(i, j) = 1 : |i - j| = 1\}$. Других ребер у графа нет. Матрица весов задается следующим образом: $W = (\omega_{ij})_{i,j=1}^n$, где

$$\omega_{ij} = \begin{cases} dist(v_i, v_j), & |i - j| = 1 \\ 0, & |i - j| \neq 1. \end{cases}$$

Весовая функция $dist$ может быть, например следующей:

- Постоянной весовой функцией: $dist(v_i, v_j) = 1$,
- Гауссовской весовой функцией: $dist(v_i, v_j) = \exp\left(\frac{-\|v_i - v_j\|_2^2}{2\sigma^2}\right)$,
- Евклидовой весовой функцией: $dist(v_i, v_j) = \|v_i - v_j\|_2$.

Пороговая обработка спектральных вейвлет коэффициентов: минимаксный порог

Каждый порог выбирается свой для каждого уровня разложения по следующей формуле [13]:

$$\tau_j = \begin{cases} \sigma_j(0.3936 + 0.1829 \cdot \frac{\ln N}{\ln 2}), & N > 32 \\ 0, & N \leq 32 \end{cases} \quad (3.9)$$

где τ_j обозначает порог на j -ом уровне разложения, N - количество спектральных вейвлет коэффициентов на j -ом уровне разложения, а σ_j оценивается по следующей формуле:

$$\sigma_j = median(\{|d_j - mean(d_j)|\}), \quad j = 1, \dots, N.$$

где d_j - это спектральные вейвлет коэффициенты на j -ом уровне разложения.

Нужно отметить, что в отличии от предыдущих методов, здесь пороговая обработка применялась только к коэффициентам, соответствующим спектральному ядру g и не применялась к коэффициентам, соответствующим функции h . Заметим, что в предыдущих методах, пороговая обработка применялась ко всем коэффициентам.

4 Численные результаты

В данной части будут рассмотрены численные результаты применения следующих двух методов: метода, основанного на применении СГВП к временным рядам, и метода, основанного на минимизации SURE.

4.1 Применение СГВП к временным рядам

В этой части представлен экспериментальный анализ представленного выше метода пороговой обработки, а также сравнение с классическими методами на синтетических данных. Данный анализ выполнен на языке Python с помощью библиотек `pywavelets` и `rugsp` [15], [11]. Для получения более надежных результатов, каждый эксперимент проводился 10 раз, а полученные оценки усреднялись. В качестве метрики качества была взята

$$SNR(x, \hat{x}) = 10 \cdot \log_{10} \left(\frac{\|x\|_2^2}{\|x - \hat{x}\|_2^2} \right),$$

где x - исходный сигнал, $\hat{x}$ - его оценка. Чем больше данная метрика качества, тем лучше.


4.1.1 Данные

Были выбраны следующие сигналы [7]:


- **Blocks:** кусочно-постоянная функция со скачками в точках $\{ 0.1, 0.13, 0.15, 0.23, 0.25, 0.40, 0.44, 0.65, 0.76, 0.78 ; 0.81 \}$.
- **Bumps:** Сумма "взрывов" в точках, совпадающих с точками прыжков в сигнале Blocks. Сам "взрыв" имеет форму $\frac{1}{1+t^4}$.
- **Doppler:** сигнал, описывающейся формулой $f(t) = \sqrt{t(1-t)} \sin \left(2\pi \cdot \frac{1.05}{t+0.05} \right)$.
- **HeaviSine:** Синусоида, имеющая период 1, с двумя скачками в точка 0.3 и 0.72.

Длина каждого из сигналов составляет 256.


Эти сигналы выбраны специально нестационарными, а также отражающими аспекты сигналов, с которыми приходится иметь дело на практике. Они представлены на рисунке 4.1.




(a) Bumps



(b) Blocks



(c) HeaviSine



(d) Doppler

Рис. 4.1: Синтетические сигналы

Генерация шума

К сигналам выше был добавлен белый аддитивный гауссовский шум с различными дисперсиями:

$$X_k = f_k + \xi_k, \quad k \in \{1, \dots, n\},$$

где X_k - k -ая компонента зашумленного сигнала, f_k - k -ая исходного сигнала, $\xi_k \sim \mathcal{N}(0, \sigma^2)$ - независимые и одинаково распределенные случайные величины. Дисперсия шума остается фиксированной $\forall k \in \{1, \dots, n\}$, $\sigma^2 \in \{0.01, 0.1, 1\}$.

Генерация графа по ряду

Был выбран граф-путь, т.к. при увеличении количества соседей для каждой точки качество оценки падало, поэтому было решено остановиться именно на нём. Были рассмотрены различные весовые функции:

- Гауссовская: $dist(v_i, v_j) = \exp\left(\frac{-||v_i - v_j||^2}{2\sigma^2}\right)$,
- Постоянная: $dist(v_i, v_j) = 1$,
- Нормированная гауссовская: $dist(v_i, v_j) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(\frac{-||v_i - v_j||^2}{2\sigma^2}\right)$,
- Евклидовая: $dist(v_i, v_j) = ||v_i - v_j||_2$,
- Гиперболическая: $dist(v_i, v_j) = 1/(0.25 + ||v_i - v_j||_2)$.

Для гауссовских весовых функции также перебирался параметр σ по сетке из 5 значений: $\{0.01, 0.1, 1, 10, 100\}$

На рисунке 4.2 представлен пример гистограммы собственных значений графа пути. Как видим, распределение собственных значений неравномерно и сконцентрировано на низких частотах.




Рис. 4.2: Гистограмма распределения собственных значений при выборе гауссовской весовой функции с параметром равным 0,01. Зашумленный сигнал Bumps, дисперсия шума 0,01.

Параметры классических методов

Для сравнения использовались вейвлеты Добеши 1-го, 2-го, 3-го и 4-го порядка, минимаксный порог и жесткая пороговая обработка, порог был выбран минимаксным.

Параметры для СГВП каркаса

Для экспериментов использовались следующие жесткие каркасы: Itersine, Meyer, SimpleTight [11]. В качестве порога был выбран минимаксный порог, а также рассматривались два типа пороговой обработки: мягкая и жесткая.

На рисунке 4.3 представлены импульсные характеристики банков фильтров Itersine, SimpleTight, Meyer. Заметим, что SimpleTight очень напоминает Meyer, т.к. этот банк фильтров является его упрощенной версией.

Далее представлены результаты только каркаса Itersine, т.к. остальные каркасы в большинстве случаев имели меньшее качество.

4.1.2 Результаты экспериментов

В зависимости от дисперсии шума были выбраны следующие параметры.

Список 4.1.2.




Рис. 4.3: Импульсные характеристики следующих банков фильтров: (a) ITERSINE, (b) SimpleTight, (c) Meyer.

1. если $\sigma^2 = 0.01$, то $J = 4$, параметр для гауссовских весовых функций = 0.01,
2. если $\sigma^2 = 0.1$, то $J = 6$, параметр для гауссовских весовых функций = 0.1,
3. если $\sigma^2 = 1$, то $J = 10$, параметр для гауссовских весовых функций = 100.




Рис. 4.4: Графики функций $const \cdot x^2 \cdot f(x)$, где $f(x)$ весовая функция. Синий цвет соответствует гауссовской весовой функции, оранжевый цвет соответствует постоянной весовой функции, зеленый цвет - евклидовой.

Полученные результаты показаны в таблице 4.1. Именно такой выбор параметра для гауссовских весовых функций может быть частично объяснен следующим образом. Весовая функция определяет веса между соседними вершинами графа пути, которые определяют матрицу Лапласа, а Лапласиан определяет какие сигналы на графе будут гладкими, а какие нет. Напомним, что произвольного сигнала $f \in \mathbb{R}^N$ справедливо равенство 2.3. Если $S(f)$ большая величина, то в преобразовании Фурье графового сигнала f будут преобладать высокие частоты и наоборот. На рисунке 4.4 изображена величина $w_{ij}(f_i - f_j)^2$ в зависимости от разницы между евклидовой нормой разности последовательных значений функции. Эта величина есть слагаемое в равенстве 2.3, которое

определяет $f^t L f$. Таким образом, задание весовой функции напрямую влияет на его будущий Фурье спектр, а значит и на СГВП разложение, которое представляет сигнал в виде суммы низкочастотного сигнала, который отвечает масштабирующей функции, и сигналов, которые соответствуют "детализирующим" вейвлет коэффициентам. Отсюда следует, что важно задать весовую функцию так, чтобы впоследствии, при применении преобразования Фурье к графовому сигналу, шум был высокочастотным (и желательно не низкочастотным), а сигналу соответствовали большие вейвлет коэффициенты. Т.к. шум нормальный, то вполне естественно предполагать, что большинство его значений будет лежать как раз примерно в диапазоне от 0 до 3σ .

Тип сигнала	Bumps			Blocks			HeaviSine			Doppler		
Тип весовой функции/ Дисперсия шума	0.01	0.1	1	0.01	0.1	1	0.01	0.1	1	0.01	0.1	1
Постоянный	34.03	15.57	2.18	42.05	23.34	11.22	52.17	34.8	17.71	33.78	14.68	-2.94
Гиперболический	39.16	19.18	-1.54	49.87	30.98	10.01	51.96	33.64	11.74	31.98	13.62	-8.29
Евклидовый	37.2	17.11	-2.13	47.91	28.06	8.66	49.97	30.88	10.33	29.51	10.32	-9.52
Гауссовский	38.67	19.71	1.71	53.05	33.5	11.79	49.3	34.01	17.37	32.13	13.74	-2.02
Нормированный гауссовский	39.14	20.43	1.89	53.45	33.1	11.76	49.19	33.53	17.11	31.77	13.41	-3.23

Таблица 4.1: Значение SNR оценки для различных типов сигналов, весовых функций и дисперсий шума. Применялась жесткая пороговая обработка. Параметры подбирались из списка 4.1.2.

На графике 4.5 представлены следующие 3 вида весовых функций:

- **Гауссовского типа:** в нуле принимают максимальное значение, а потом при увеличении аргумента быстро стремятся к нулю.
- **Постоянного типа:** являются константной на всей числовой прямой.
- **Евклидового типа:** в нуле принимают значение ноль, а при увеличении аргумента стремятся к $+\infty$.

Из таблиц 4.3, 4.1 можно сделать вывод, что самыми лучшими являются весовые функции гауссовского типа. При большом шуме также хороший результат показывают весовые функции постоянного типа, однако весовые функции евклидового типа показали в данном эксперименте плохое качество по сравнению с другими методами.

Тип сигнала	Bumps			Blocks			HeaviSine			Doppler		
Тип вейвлета/ Дисперсия шума	0.01	0.1	1	0.01	0.1	1	0.01	0.1	1	0.01	0.1	1
Данные	36.88	16.86	-3.1	47.85	27.82	7.86	49.8	29.81	9.79	29.34	9.37	-10.63
Добеши 1-го порядка	33.94	18.63	-1.04	51.28	30.6	10.08	25.98	25.48	11.94	22.83	10.54	-8.2
Добеши 2-го порядка	34.61	18.33	-1.1	50.92	29.5	9.91	47.1	32.14	11.96	29.89	11.28	-8.34
Добеши 3-го порядка	37.38	18.42	-1.03	48.41	30.2	9.69	52.29	32.25	12.12	30.7	11.35	-8.33
Добеши 4-го порядка	34.37	18.31	-1.14	40.66	29.02	9.84	52.26	32.03	12.08	31.63	11.42	-8.23

Таблица 4.2: Значение SNR оценки классического метода пороговой обработки в зависимости от различного типа сигнала, вейвлета и дисперсии шума.




Рис. 4.5: 3 различных типа весовых функций

4.1.3 Интерпретация полученных результатов

Выбор весовой функции и уровня декомпозиции J сильно влияет на последующее качество оценки сигнала. При правильном подборе параметров весовые функции гауссовского типа показывают хороший результат см. таблицу 4.3. На основе экспериментального анализа можно сделать следующие выводы:

- Если сигнала в шуме достаточно много, то в качестве весовой функции можно выбрать весовую функцию гауссовского типа с параметром, примерно равным дисперсии шума.
- Если в сигнале шума больше, чем полезного сигнала, то в качестве весовой функции можно выбрать весовую функцию постоянного типа.

Тип сигнала	Bumps			Blocks			HeaviSine			Doppler		
Тип весовой функции/ Дисперсия шума	0.01	0.1	1	0.01	0.1	1	0.01	0.1	1	0.01	0.1	1
Постоянный	28.66	16.60	1.90	14.87	14.92	11.58	52.08	33.85	18.07	33.67	14.66	-2.94
Гиперболический	38.81	20.47	1.23	35.91	29.38	10.48	51.92	34.06	13.25	32.80	14.45	-8.29
Евклидовый	36.77	16.87	-1.0	47.88	28.95	8.376	50.05	32.05	12.66	30.15	9.859	-9.51
Гауссовский	39.61	18.94	2.15	55.84	35.32	13.34	53.02	36.81	18.53	33.75	14.73	-2.02
Нормированный гауссовский	39.58	19.15	1.92	55.58	35.43	12.31	54.00	35.19	17.21	34.04	14.90	-3.23

Таблица 4.3: Значение SNR оценки для различных типов сигналов, весовых функций и дисперсий шума. Использовалась жесткая и мягкая пороговая обработка. Здесь параметры для гауссовских весовых функций и уровня разложения J подбирались так, чтобы максимизировать их качество.

Как показывают эксперименты, при правильном подборе параметров метод, основанный на СГВП, имеет хорошую способность удалять шум.

4.2 Применение SURE порога

Везде ниже в качестве графа был использован Pittsburgh Census Tract Graph, который состоит из 402 вершин и 2382 ребер. Нижеприведенный анализ выполнен с использованием языка R и библиотека gasper [10].

4.2.1 Генерация сигнала

Для генерации сигнала был использован метод, который был предложен в [16]. Пусть

$$y_{\eta,n} = x_{\eta,n} + \varepsilon.$$

где $x_{\eta,n} \in \mathbb{R}^N$ - графовый сигнал плотности $\eta \in [0, 1]$ и гладкости $n \in \mathbb{Z}^+$, $\varepsilon \in \mathbb{R}^N$ - аддитивный гауссовский белый шум с дисперсией σ_ε^2 . Графовый сигнал $x_{\eta,n}$ получается следующим образом:

$$x_{\eta,n} = A^n p_\eta.$$

где $p_\eta \in \mathbb{R}^N$ обозначает графовый сигнал, компоненты которого являются бернуллиевскими случайными величинами, причем $\sum_{i=1}^N p_\eta[i] = \eta N$.

В данной работе были выбраны следующие параметры для генерации сигнала: $\eta = 0.01$, $n = 5$, $\sigma_\varepsilon^2 \in \{0.005, 0.01, 0.02\}$.

β	1.30	3.475	5.650	7.825	10.0	20.0
$SNR_{\hat{\sigma}}^{SURE}$	10.40	11.15	11.15	11.53	11.63	11.73
SNR_{σ}^{MSE}	11.78	12.23	12.37	12.37	12.37	12.30

Таблица 4.4: SNR оценки при дисперсии шума равной 0.005, кусочно-постоянном выборе каркаса и уровне разложения $J = 11$. Использовался координатный способ выбора порога. строка $SNR_{\hat{\sigma}}^{SURE}$ означает SNR оценку, которая получается при минимизации SURE с оценкой σ , строка SNR_{σ}^{MSE} означает SNR оценку, которая получается при минимизации MSE с точным значением σ .

Параметры метода

Пороговая функция задавалась как

$$\tau(x, t) = x \max\{1 - t^{\beta}|x|^{-\beta}, 0\}, \beta \geq 1,$$

где параметр β перебирался по следующим значениям $\{1.3, 3.475, 5.65, 7.825, 10.0, 20.0\}$.

СГВП каркас задавался с помощью кусочно-постоянного фильтра банков 2.2 и фильтра банков, который адаптируется к сигналу [16].

В данной задаче рассматривались два типа выбора порога: универсальная и координатная. В первом случае, выбирается один порог для всех вейвлет коэффициентов и минимизируется SURE по этому порогу, а во втором случае, для каждого вейвлет коэффициента выбирается свой порог и уже по всем $n(J + 1)$ порогам минимизируется SURE.

4.2.2 Результаты экспериментов

Из результатов, которые представлены в таблице 4.4, можно сделать вывод, что пороговая функция имеет большое значение при фильтрации сигнала. Так например, для кусочно-постоянного каркаса зависимость монотонная по β , а для адаптируемого каркаса зависимость унимодальна по β .

Как видно из таблицы 4.5, координатная пороговая обработка лучше, чем универсальная. Также заметно, что адаптируемый каркас справился немного лучше, чем кусочно-постоянный, однако незначительно и что, SURE является хорошей оценкой MSE, т.к. минимизируя его, получаем близкую оценку к оценке, полученной при минимизации MSE.

На рисунке 4.6 представлен график SNR оценки, полученной при минимизации SURE по параметрам J , β и по типу каркаса. В большинстве случаев маленькое значение SURE соответствует большому значению SNR оценки.

Дисперсия шума	SNR_{σ}^{SURE}	$SNR_{\hat{\sigma}}^{MSE}$	Тип порога	Каркас
0.005	7.71	8.01	Универсальный	Адаптируемый
	7.81	8.22	Универсальный	Не адаптируемый
	12.25	12.27	Координатный	Адаптируемый
	11.53	12.37	Координатный	Не адаптируемый
0.02	-0.04	0	Универсальный	Адаптируемый
	-0.16	0	Универсальный	Не адаптируемый
	4.45	4.52	Координатный	Адаптируемый
	4.27	4.31	Координатный	Не адаптируемый

Таблица 4.5: SNR оценки при дисперсии шума равной 0.02 и 0.005, кусочно-постоянном выборе каркаса и уровне разложения $J = 11$, $\beta = 7.825$. Столбец SNR_{σ}^{SURE} соответствует SNR оценки, которая получается при минимизации SURE и оценки $\hat{\sigma}$, столбец SNR_{σ}^{MSE} соответствует SNR оценки, которая получается при минимизации MSE с точным значением σ .




Рис. 4.6: Зависимость качества решения от оценки SURE. Дисперсия шума равна 0.01

4.2.3 Интерпретация полученных результатов

В ходе экспериментального анализа были замечены следующие выводы:

- Качество оценки сильно зависит от выбора пороговой функции, а точнее, параметра β . Было замечено, что хорошие результаты в данной задаче получаются при $\beta = 7.825$. Такой выбор отражает баланс между мягкой и жесткой пороговой обработкой.
- Выбор порога также оказывается важным фактором: координатная показала более лучшие результаты, чем универсальная.
- Выбор каркаса не сыграл значительной роли, можно отметить, что в данной задаче адаптируемый каркас проявил себя чуть лучше, чем кусочно-постоянный.

- SURE дает в большинстве случаев разумную оценку MSE, но отсюда не следует, что минимальному значению SURE соответствует минимальное значение MSE.

5 Заключение

В данной работе исследовались методы обработки графовых сигналов и временных рядов, в которых применялись 2 типа порогов: универсальный и SURE, а также различные виды пороговой обработки. Был дан обзор теоретических результатов вышеописанных методов. В частности, для универсального порога с мягкой пороговой обработки было показано в [2], что он также удовлетворяет неравенству с оракулом, такому же как и в классическом случае.

Рассмотрен метод оценки дисперсии шума для нерегулярных сигналов.

На синтетических данных SURE оказался хорошей оценкой риска, а также было продемонстрировано, как с его помощью можно подбирать параметры для пороговой обработки.

Что касается сложности методов, основанных на СГВТ, то главное ограничение по времени состоит в полной факторизации Лапласиана. Главное ограничение по памяти это необходимость хранить матрицу $\mathcal{W}$, которая имеет $O(n^2(J+1)^2)$ элементов. Однако, если факторизация Лапласиана уже сделана, то временная сложность алгоритма существенно уменьшается до $O(n(J+1)\log(n(J+1)))$.

Однако, эта полная факторизация Лапласиана, вовсе не является необходимостью. Данный шаг может быть существенно оптимизирован с помощью многочленов Чебышева [1] с любой наперед заданной точностью.

В методе обработки временных рядов были исследованы различные типы весовых функций. Лучше всего показали себя весовые функции гауссовского типа, но параметр в них нужно подбирать в соответствии с оценкой дисперсии шума. Приведено сравнение с классическими методами.

В результате экспериментального анализа, было продемонстрировано, что методы, основанные на СГВП, можно эффективно применять к нерегулярным и регулярным сигналам.

Литература

- [1] David K. Hammond, Pierre Vandergheynst, Rémi Gribonval. *The Spectral Graph Wavelet Transform: Fundamental Theory and Fast Computation*.
- [2] Göbel, F., Blanchard, G., and von Luxburg, U. (2018). *Construction of tight frames on graphs and application to denoising*. In Handbook of big data analytics, Springer Handb. Comput. Stat., pages 503–522. Springer, Cham.
- [3] Т.В.Захарова, О.В.Шестаков. *Теория вейвлетов и ее применение в обработке сигналов: Учебное пособие* . - Москва, 2018.
- [4] Малла С. *Вейвлеты в обработке сигналов*. Москва, 2005
- [5] Kereta, Z., Vigogna, S., Naumova, V., Rosasco, L., and De Vito, E. (2019). *Monte carlo wavelets: a randomized approach to frame discretization*. In 2019 13th International conference on Sampling Theory and Applications (SampTA), pages 1–5. IEEE.
- [6] Stein, C. M. (1981). *Estimation of the mean of a multivariate normal distribution*. Ann. Statist., 9(6):1135–1151.
- [7] Donoho, D. L. and Johnstone, I. M. (1995). *Adapting to unknown smoothness via wavelet shrinkage*. J. Amer. Statist. Assoc., 90(432):1200–1224.
- [8] Basile de Loynes, Fabien Navarro, and Baptiste Olivier. *Data-driven thresholding in denoising with spectral graph wavelet transform*. J. Comput. Appl. Math., 389:113319, 12, 2021
- [9] A. Ortega, P. Frossard, J. Kovačević, J. M. F. Moura and P. Vandergheynst, "*Graph Signal Processing: Overview, Challenges, and Applications*," in Proceedings of the IEEE, vol. 106, no. 5, pp. 808-828, May 2018, doi: 10.1109/JPROC.2018.2820126.
- [10] de Loynes B, Navarro F, Olivier B (2020). "*Gasper: GrAph Signal ProcEssing in R*." 2007.10642.
- [11] *PyGSP: Graph Signal Processing in Python*, Defferrard, Michael and Martin, Lionel and Pena, Rodrigo and Perraudin, Nathanael, doi:10.5281/zenodo.1003157.
- [12] X. Dong, A. Ortega, P. Frossard, P. Vandergheynst, "*Inference of mobility patterns via spectral graph wavelets*", in: IEEE International Conference on Acoustics, Speech and Signal Processing, 2013, pp. 3118–3122.

- [13] Xin Dong, Guolong Li, Yachao Jia, Biao Li, Kun He, "*Non-iterative denoising algorithm for mechanical vibration signal using spectral graph wavelet transform and detrended fluctuation analysis*", Mechanical Systems and Signal Processing, Volume 149, 2021, 107202, ISSN 0888-3270, <https://doi.org/10.1016/j.ymssp.2020.107202>.
- [14] L. Stankovic, D. P. Mandic, M. Dakovic, I. Kisil, E. Sejdic and A. G. Constantinides, "*Understanding the Basis of Graph Signal Processing via an Intuitive Example-Driven Approach [Lecture Notes]*," in IEEE Signal Processing Magazine, vol. 36, no. 6, pp. 133-145, Nov. 2019, doi: 10.1109/MSP.2019.2929832.
- [15] Lee G, Gommers R, Wasilewski F, Wohlfahrt K, O'Leary A, Nahrstaedt H, and Contributors. *PyWavelets - Wavelet Transforms in Python*. [Электронный ресурс]// URL: <https://pywavelets.readthedocs.io/en/latest/>
- [16] H. Behjat, U. Richter, D. Van De Ville and L. Sörnmo, "*Signal-Adapted Tight Frames on Graphs*," in IEEE Transactions on Signal Processing, vol. 64, no. 22, pp. 6017-6029, 15 Nov.15, 2016, doi: 10.1109/TSP.2016.2591513.