


Спектральное вейвлет преобразование для задачи непараметрической регрессии

Педашенко Владислав Евгеньевич


Московский государственный университет имени М.В. Ломоносова
Научный руководитель: д.ф.-м.н. профессор Шестаков О.В.

1 июня 2022 года

Введение



(a) Электроэнцефалограмма.



(b) Социальная сеть.

Рис.: Примеры данных, обладающих структурой, которая может быть описана графом.

Пример сигнала на графе

- Вершины:
 - участки мозга
- Ребра:
 - структурная связность между участками мозга
 - веса показывают насколько сильно участки мозга согласованы.
- Сигнал:
 - Временные ряды, зависящие от уровня кислорода в крови.





Рис.: Энценофалограмма

Частотная область



Пусть $G = \{\mathcal{V}, \mathcal{E}\}$ - взвешенный и неориентированный граф.

$$D = \text{diag}(d(v_1), \dots, d(v_N)).$$

$$L = D - W.$$

- Симметричен.
- Неотрицательно определен.
- Является аппроксимацией одномерного оператора Лапласа

Рис.: Сигнал на графе

Сравнение преобразований Фурье

Пусть справедливо: $L\chi_I = \lambda_I\chi_I$.

- Оператор Лапласа : $-\nabla^2$
- Собственные функции: $e^{i\omega x}$
- Классическое преобразование Фурье:
- Лапласиан: L .
- Собственные векторы: χ_I
- Графовое преобразование Фурье:

$$\hat{f}(\omega) = \int (e^{i\omega x})^* f(x) dx.$$

$$f(x) = \frac{1}{2\pi} \int \hat{f}(\omega) e^{i\omega x} d\omega.$$

$$\hat{f}(I) = \langle \chi_I, f \rangle = \sum_{i=1}^N \chi_I^*(i) f(i).$$


$$f(i) = \sum_{I=1}^N \hat{f}(I) \chi_I(i).$$

Вейвлеты

Вейвлет $\psi(t)$, $\int_{\mathbb{R}} \psi(t)dt = 0$, $\psi_{u,s}(t) = \frac{1}{\sqrt{s}}\psi(\frac{t-u}{s})$.



(a) Вейвлет



(b) Масштабирование и перенос

Вейвлет коэффициенты: $\langle f, \psi_{u,s} \rangle = \int f(t)\psi_{u,s}(t)dt$

Вейвлет преобразование обратимо и имеет
частотно-временную локализацию.

Непрерывное вейвлет преобразование




Рис.: (а) - вершина, вокруг которой сконцентрированы вейвлеты, (б) - масштабирующая функция, (с)-(ф) вейвлеты с различным масштабом

Спектральное графовое вейвлет преобразование

Вейвлет-преобразование можно обобщить на нерегулярный случай. Одно из возможных обобщений является спектральное графовое вейвлет преобразование. В частности, оно тоже обладает свойством частотно-временной локализации.

Спектральное графовое вейвлет преобразование

Пусть $\{t_j\}_{j=1}^J$ - набор масштабов, NJ вейвлетов $\psi_{t_j,n}$ и N масштабирующих функций ϕ_n .




Рис.: (a) - вершина, вокруг которой сконцентрированы вейвлеты, (b) - масштабирующая функция, (c)-(f) вейвлеты с различным масштабом

Постановка задачи

Пусть

$$y_i = x_i + \xi_i, \quad i \in \{1, \dots, N\}, \quad (1)$$

где y_i - i -ая компонента наблюдаемого графового сигнала, которая соответствует i -ой вершине, $x = (x_1, \dots, x_N)$ - исходный графовый сигнал, $\xi_i \sim \mathcal{N}(0, \sigma^2)$ - независимые и одинаково распределенные случайные величины.

Универсальный порог

Пусть $\{\sqrt{\psi_{k,l}}\}$ СГВП, построенное специальным образом.

$S_s(z, c) = \text{sgn}(z) \max\{|z| - c, 0\}$ - пороговая функция, соответствующая мягкой пороговой обработке.

$$\hat{x}_S = \sum_{k,l} S_s(\langle y, \sqrt{\psi_{k,l}} \rangle, c_{k,l}) \cdot \sqrt{\psi_{k,l}}, \text{ где } c_{kl} = \sigma \|\sqrt{\psi_{k,l}}\|.$$

$\hat{x}_S$ - оценка исходного сигнала.

Введем оценку оракула следующим образом: оракул знает исходный сигнал и над каждым вейвлет коэффициентом он может сделать два действия: занулить его или оставить, тогда оценка риска равна:

$$\min_l \mathbb{E} (\|\hat{x}_l - x\|^2) = \sum_{(k,l)} \min \left(\langle x, \sqrt{\psi_{k,l}} \rangle^2, \sigma^2 \|\sqrt{\psi_{k,l}}\|^2 \right) = r_{\min}(x) \quad (2)$$

Теорема [2]: Пусть $\mathfrak{F} = \{\sqrt{\psi_{k,j}}\}$ - регулярный каркас Парсевалья,

$$\hat{x}_S = \sum_{k,l} S_s(\langle y, \sqrt{\psi_{k,l}} \rangle, t_{k,l}) \cdot \sqrt{\psi_{k,l}} - \text{оценка, полученная с помощью}$$

мягкой пороговой обработки. Тогда, если $t_{k,l} = \sigma \|\sqrt{\psi_{k,l}}\| \sqrt{2 \log(n)}$, то справедливо следующее неравенство:

$$\mathbb{E}(\|\hat{x}_S - x\|^2) \leq (2 \log(n) + 1)(\sigma^2 + r_{\min}(x)) \quad (3)$$

SURE порог

Этот метод выбора порога основан на минимизации SURE.
Применяя СГВП слева и справа в равенстве 1, что эквивалентно умножению на специальную матрицу $\mathcal{W}$. Получим:

$$Y = X + \Xi \quad (4)$$

где $Y = \mathcal{W}y$, $X = \mathcal{W}x$, $\mathcal{W}\xi = \Xi \sim \mathcal{N}(0, \sigma^2 \mathcal{W}\mathcal{W}^*)$.

Пороговая функция $\tau(x, t)$: $\tau(x, t) = x \max\{1 - t^\beta |x|^{-\beta}, 0\}$, где $\beta \geq 1$, x - вейвлет коэффициент, t - порог.

Теорема:[4] В вышеописанных условиях SURE имеет вид:

$$\begin{aligned} SURE = & -n\sigma^2 + \sum_{i=1}^{n(J+1)} Y_i^2 \left(\min \left\{ 1, \frac{t_i^\beta}{|Y_i|^\beta} \right\} \right)^2 + \\ & 2 \sum_{i=1}^n \mathbb{D}(\Xi_i) \mathbb{1}_{[t_i, +\infty)}(|Y_i|) \left[1 + \frac{(\beta-1)t_i^\beta}{|Y_i|^\beta} \right] \end{aligned}$$


Применение к одномерным данным

Этот метод удаления шума состоит из четырех частей:

- Построение графа и графового сигнала по временному ряду.
- Применение СГВП к графовому сигналу.
- Применение пороговой обработки к спектральным вейвлет коэффициентам.
- Применение обратного СГВП преобразования. Порог - минимаксный.

Построение графа

Был выбран граф-путь.



Весовая функция

Весовая функция *dist* может быть, например следующей:

- Постоянной весовой функцией:

$$\text{dist}(v_i, v_j) = 1,$$

- Гауссовской весовой функцией:

$$\text{dist}(v_i, v_j) = \exp\left(\frac{-\|v_i - v_j\|_2^2}{2\sigma^2}\right),$$

- Евклидовой весовой функцией:

$$\text{dist}(v_i, v_j) = \|v_i - v_j\|_2.$$


Результаты: SURE

Дисперсия шума	SNR_{σ}^{SURE}	$SNR_{\hat{\sigma}}^{MSE}$	Тип порога	Каркас
0.005	7.71	8.01	Универсальный	Адаптируемый
	7.81	8.22	Универсальный	Не адаптируемый
	12.25	12.27	Координатный	Адаптируемый
	11.53	12.37	Координатный	Не адаптируемый
0.02	-0.04	0	Универсальный	Адаптируемый
	-0.16	0	Универсальный	Не адаптируемый
	4.45	4.52	Координатный	Адаптируемый
	4.27	4.31	Координатный	Не адаптируемый

Таблица: SNR оценки при дисперсии шума равной 0.02 и 0.005, кусочно-постоянном выборе каркаса и уровне разложения $J = 11$, $\beta = 7.825$. Столбец $SNR_{\hat{\sigma}}^{SURE}$ соответствует SNR оценки, которая получается при минимизации SURE и оценки $\hat{\sigma}$, столбец SNR_{σ}^{MSE} соответствует SNR оценки, которая получается при минимизации MSE с точным значением σ .

График SURE

Зависимость качества решения от значения SURE



Применение к временным рядам

Тип сигнала	Bumps			Blocks		
Тип весовой функции/ Дисперсия шума	0.01	0.1	1	0.01	0.1	1
Постоянный	34.03	15.57	2.18	42.05	23.34	11.22
Гиперболический	39.16	19.18	-1.54	49.87	30.98	10.01
Евклидовый	37.2	17.11	-2.13	47.91	28.06	8.66
Гауссовский	38.67	19.71	1.71	53.05	33.5	11.79
Нормированный гауссовский	39.14	20.43	1.89	53.45	33.1	11.76

Таблица: Значение SNR оценки для различных типов сигналов, весовых функций и дисперсий шума. Применялась жесткая пороговая обработка. Параметры подбирались из списка ??.

Тип сигнала	Bumps			Blocks		
Тип вейвлета/ Дисперсия шума	0.01	0.1	1	0.01	0.1	1
Данные	36.88	16.86	-3.1	47.85	27.82	7.86
Добеши 1-го порядка	33.94	18.63	-1.04	51.28	30.6	10.08
Добеши 2-го порядка	34.61	18.33	-1.1	50.92	29.5	9.91
Добеши 3-го порядка	37.38	18.42	-1.03	48.41	30.2	9.69
Добеши 4-го порядка	34.37	18.31	-1.14	40.66	29.02	9.84

Таблица: Значение SNR оценки классического метода пороговой обработки в зависимости от различного типа сигнала, вейвлета и дисперсии шума.

Выводы

- В данной работе исследовались методы обработки графовых сигналов и временных рядов, в которых применялись 2 типа порогов: универсальный и SURE, а также различные виды пороговой обработки.
- Был дан обзор теоретических результатов вышеописанных методов. В частности, для универсального порога с мягкой пороговой обработки было показано в [2], что он также удовлетворяет неравенству с оракулом, такому же как и в классическом случае.
- Рассмотрен метод оценки дисперсии шума для нерегулярных сигналов.
На синтетических данных SURE оказался хорошей оценкой риска, а также было продемонстрировано, как с его помощью можно подбирать параметры для пороговой обработки.
- В методе обработки временных рядов были исследованы различные типы весовых функций. Лучше всего показали себя весовые функции гауссовского типа, но параметр в них нужно подбирать в соответствии с оценкой дисперсии шума.
Приведено сравнение с классическими методами.
- В результате экспериментального анализа, было продемонстрировано, что методы, основанные на СГВП, можно эффективно применять к нерегулярным и регулярным сигналам.

Список литературы:



David K. Hammond, Pierre Vandergheynst, Rémi Gribonval. *The Spectral Graph Wavelet Transform: Fundamental Theory and Fast Computation*.



Göbel, F., Blanchard, G., and von Luxburg, U. (2018). *Construction of tight frames on graphs and application to denoising*. In Handbook of big data analytics, Springer Handb. Comput. Stat., pages 503–522. Springer, Cham.



Т.В.Захарова, О.В.Шестаков. *Теория вейвлетов и ее применение в обработке сигналов: Учебное пособие*. Москва, 2018.



Basile de Loynes, Fabien Navarro, and Baptiste Olivier. *Data-driven thresholding in denoising with spectral graph wavelet transform*. J. Comput. Appl. Math., 389:113319, 12, 2021



Малла С. *Вейвлеты в обработке сигналов*. Москва, 2005



Kereta, Z., Vigogna, S., Naumova, V., Rosasco, L., and De Vito, E. (2019). *Monte carlo wavelets: a randomized approach to frame discretization*. In 2019 13th International conference on Sampling Theory and Applications (SampTA), pages 1–5. IEEE.

Список литературы:



Stein, C. M. (1981). *Estimation of the mean of a multivariate normal distribution*. Ann. Statist.,9(6):1135–1151.



Donoho, D. L. and Johnstone, I. M. (1995). *Adapting to unknown smoothness via wavelet shrinkage*. J. Amer. Statist. Assoc., 90(432):1200–1224.



A. Ortega, P. Frossard, J. Kovačević, J. M. F. Moura and P. Vandergheynst, "*Graph Signal Processing: Overview, Challenges, and Applications*," in Proceedings of the IEEE, vol. 106, no. 5, pp. 808-828, May 2018, doi: 10.1109/JPROC.2018.2820126.



H. Behjat, U. Richter, D. Van De Ville and L. Sörnmo, "*Signal-Adapted Tight Frames on Graphs*," in IEEE Transactions on Signal Processing, vol. 64, no. 22, pp. 6017-6029, 15 Nov.15, 2016, doi: 10.1109/TSP.2016.2591513.

Минимаксный порог

$$\tau_j = \begin{cases} \sigma_j(0.3936 + 0.1829 \cdot \frac{\ln N}{\ln 2}), & N > 32 \\ 0, & N \leq 32 \end{cases} \quad (5)$$

Генерация сигнала при SURE

Для генерации сигнала был использован метод, который был предложен в [4]. Пусть

$$y_{\eta,n} = x_{\eta,n} + \varepsilon.$$

где $x_{\eta,n} \in \mathbb{R}^N$ - графовый сигнал плотности $\eta \in [0, 1]$ и гладкости $n \in \mathbb{Z}^+$, $\varepsilon \in \mathbb{R}^N$ - аддитивный гауссовский белый шум с дисперсией σ_ε^2 . Графовый сигнал $x_{\eta,n}$ получается следующим образом:

$$x_{\eta,n} = A^n p_\eta.$$

где $p_\eta \in \mathbb{R}^N$ обозначает графовый сигнал, компоненты которого являются бернуллиевскими случайными величинами, причем

$$\sum_{i=1}^N p_\eta[i] = \eta N$$

В данной работе были выбраны следующие параметры для генерации сигнала: $\eta = 0.01$, $n = 5$, $\sigma_\varepsilon^2 \in \{0.005, 0.01, 0.02\}$.